

学 号： 2016212063

密 级： 公开

合肥工业大学

Hefei University of Technology

本科毕业设计（论文）

UNDERGRADUATE THESIS



类 型： 设计

题 目： 基于深度学习的金融文本风险分析
系统设计实现

专业名称： 计算机科学与技术

入校年份： 2016 级

学生姓名： 任恒

指导教师： 李培培 副研究员

学院名称： 计算机与信息学院

完成时间： 2020 年 5 月

合 肥 工 业 大 学

本科毕业设计（论文）

基于深度学习的金融文本
风险分析系统设计与实现

学生姓名：_____任恒_____

学生学号：_____2016212063_____

指导教师：_____李培培 副研究员_____

专业名称：_____计算机科学与技术_____

学院名称：_____计算机与信息学院_____

2020 年 5 月

A Dissertation Submitted for the Degree of Bachelor

**Design and Implementation of Financial Text Risk
Analysis System Based on Deep Learning**

By

Ren Heng

Hefei University of Technology

Hefei, Anhui, P.R.China

May, 2018

毕业设计（论文）独创性声明

本人郑重声明：所呈交的毕业设计（论文）是本人在指导教师指导下进行独立研究工作所取得的成果。据我所知，除了文中特别加以标注和致谢的内容外，设计（论文）中不包含其他人已经发表或撰写过的研究成果，也不包含为获得合肥工业大学或其他教育机构的学位或证书而使用过的材料。对本文成果做出贡献的个人和集体，本人已在设计（论文）中作了明确的说明，并表示谢意。

毕业设计（论文）中表达的观点纯属作者本人观点，与合肥工业大学无关。

毕业设计(论文)作者签名: 签名日期: 年 月 日

毕业设计（论文）版权使用授权书

本学位论文作者完全了解合肥工业大学有关保留、使用毕业设计(论文)的规定,即:除保密期内的涉密设计(论文)外,学校有权保留并向国家有关部门或机构送交设计(论文)的复印件和电子光盘,允许设计(论文)被查阅或借阅。本人授权合肥工业大学可以将本毕业设计(论文)的全部或部分内容编入有关数据库,允许采用影印、缩印或扫描等复制手段保存、汇编毕业设计(论文)。

(保密的毕业设计(论文)在解密后适用本授权书)

学位论文作者签名: 指导教师签名:

签名日期: 年 月 日 签名日期: 年 月 日

摘 要

实际应用领域产生了大量的金融数据，而对金融数据进行分析有助于实现市场的监管。本文基于深度学习方法设计并实现了一个针对金融领域的真实公司公告文本的风险分析系统。

首先，针对获取的金融领域的公司公布文本，研究并实现一种命名实体识别算法，在已有的基于字的算法基础上，该算法通过使用额外的 LSTM 格子将句子中的潜在词添加到基于字的 LSTM-CRF 模型中，即在每一时刻通过归一化方式，将当前输入字结合已输入的文字序列中以当前输入字为结尾的词语替换原有输入字。最终该模型取得了很好的效果。

其次，为了得到文本的风险等级，采用了 fasttext 算法对经过筛选的公告进行训练，得到每一个公告正文对应的文本类型，并对每一个类型赋予一个风险等级，若存在多个风险等级，那么将对其进行加权和处理。为了能够直观的参考算法提供的分类结果，本文采用 lime 模型对影响分类结果的特征进行筛选，得到影响模型较大的参数。

进而，研究并修改了文本摘要模型，以经过筛选的公告标题为目标摘要，以公告正文为对象进行模型训练，在 pointer-generator 模型训练速度不佳的情况下将其编码层从 LSTM 替换为 transformer 的 encoder 层并且在速度上有很大的提升。

最后，基于上述功能，设计并实现了面向金融领域公司公告文本的风险分析系统。该系统采用 B/S 架构，前端采用 vue 框架，后端基于 Flask 框架，利用 javascript、v-Echart 进行布局及展示，系统提供了公司公告设计涉及的实体、类别、风险等级与分析、摘要、重要词语的展示功能。

关键词：风险分析系统；命名实体识别；文本摘要；文本分类；金融数据；

ABSTRACT

Large amounts of financial data have been produced in the real-world applications, and analyzing financial data is beneficial to supervise markets. This dissertation uses the real company announcement texts, and implements a public opinion analysis system based on deep learning methods.

Firstly, aiming at the acquired texts of companies in the financial field, a named entity recognition algorithm is implemented. Based on the existing character-based algorithm, this algorithm adds the potential words in the sentence to the word-based LSTM-CRF model. In other words, the current input word is combined with the words in the input text sequence that end with the current input word to replace the original input word at each moment by normalization. In the end, the model achieved good results.

Secondly, in order to obtain the risk level of the text, the fasttext algorithm is used to train on the filtered announcements. The text type can be obtained corresponding to each announcement body, and a risk level is assigned to each type. If there are multiple risk levels, then it is weighted and processed. In order to intuitively refer to our classification results, this dissertation uses the lime model to filter the features that affect the classification results, and obtains the larger parameters that affect the model for intuitive reference.

Thirdly, the text summary model is studied and modified. We took the filtered announcement title as the target abstract, and the announcement body as the object for model training. If the pointer-generator model training speed is bad, its coding layer is replaced from LSTM. The encoder layer of the transformer has greatly improved in speed.

Finally, in terms of the above functions, an opinion analysis system is designed and implemented. This system adopts the B/S architecture, uses the vue framework for the front end, uses the Flask framework for the back end, and combines javascript and v-echart for the layout. This system shows the functions related to company terms, risk categories, displaying and analysis of risks, summaries, and important words.

KEYWORDS: risk analysis system; named entity recognition; text summary; text classification; financial data;

目 录

1 绪论	1
1.1 课题背景与研究意义	1
1.1.1 课题背景	1
1.1.2 研究现状	1
1.1.3 研究意义	3
1.2 金融文本风险界定及文本特点	3
1.3 论文组织结构	4
1.3.1 论文的主要工作	4
1.3.2 论文结构安排	5
1.4 本章小结	6
2 需求分析与系统设计	7
2.1 需求分析	7
2.1.1 用户使用背景	7
2.1.2 预期数据处理类型	7
2.1.3 系统功能目标	7
2.1.4 使用对象	8
2.2 系统技术方案	8
2.3 系统框架设计	9
2.4 本章小结	10
3 系统模块实现	11
3.1 基于 Lattice LSTM 的命名实体提取	11
3.2 基于 fasttext 的文本风险等级确定	16
3.2.1 公告类别确定	16
3.2.2 公告风险系数确定	20
3.3 文本摘要生成及改进	21
3.4 基于 lime 的结果解释	25
3.5 本章小结	26
4 系统功能与测试	27
4.1 实体识别模块	27

4.2 摘要生成	28
4.3 文本类别与风险等级	28
4.4 风险原因解释	29
4.5 批量文件处理	29
4.6 本章小结	30
5 总结与展望	31
5.1 工作总结	31
5.2 工作展望	32
参考文献	33
致谢	35
附录	36

插图清单

图 2.1 系统架构	9
图 2.2 数据流图	10
图 3.1 基于字的 LSTM 模型	11
图 3.2 基于词的 LSTM 模型	12
图 3.3 Lattice LSTM 模型	12
图 3.4 词典存储格式	15
图 3.5 实体识别过程	15
图 3.6 准确率变化表	16
图 3.7 公告文本长度分布	18
图 3.8 fasttext 模型结构	19
图 3.9 基于分词的 fasttext 分类精度	20
图 3.10 Pointer-Generator Network 模型	22
图 3.11 基于 transformer 编码层的实现	24
图 3.12 transformer 编码层	25
图 4.1 前端展示页面	27
图 4.2 文本摘要结果	28
图 4.3 类别判定结果以及风险结果	29
图 4.4 风险影响因素	29
图 4.5 上传文件样式	30
图 4.6 服务器端文件列表	30
图 4.7 下载本地文件结果	30

表格清单

表 3.1 NER 训练集格式.....	14
表 3.2 部分风险类别规则	17
表 3.3 两种模型的测试结果	20
表 3.4 风险系数对照表	21
表 3.5 lime 影响因素分析样例	26

1 绪论

1.1 课题背景与研究意义

1.1.1 课题背景

随着经济的发展，各种公司林林总总，如雨后春笋般竞相出现，公司业务等产生了大量的金融文本数据；如果仅依靠人力来对大量的金融文本进行分析变得越来越不现实。同时随着互联网时代的发展，公司的相关信息都会依照如证监会等监督部门的要求在其网站上公布，多涉及一个公司的人员变更、营收状况、发展规划、贪污腐败、公司分支等经营情况，这为金融数据的自动化批量处理及其对其中隐含的风险分析提供了数据支持。已有研究表明，公司所发出的各种信息对投资机构以及投资个人的投资方向有重要的影响，通过对公司公告的分析，可以准确分析其股票可能的走势情况。本文首先通过爬虫技术从若干公司及证监会等部门获得其公告文件，并通过文本解析技术将文件中的文本内容以及图表内容解析出来，基于获取的金融文本数据，旨在利用深度学习方法挖掘隐含在公告文本中的潜在信息，为金融领域的市场监管提供有效决策支持。

1.1.2 研究现状

本节将主要介绍命名实体识别、文本摘要以及金融文本处理三方面的相关工作。

命名实体识别：近年来使用深度学习技术来处理命名实体识别（NER）问题正逐渐成为趋势，此外由于中文结构的多样性以及内容的复杂性，目前较好的模型很多也是基于英文模型的更改。在机器学习中运用统计学知识的条件随机场（CRF）^[1]模型以及隐马尔可夫模型（HMM）等模型相对于传统的方法有较大的改进，在这多种模型中 HMM 表现效果相较于其他几种有明显的优势。随着计算机性能的进一步提升，CPU 速度以及 GPU 的加速，基于深度学习和生成对抗网络的方法也逐渐展示出其在命名实体识别领域中的强大能力，其中当然也包括相应的搭配研究的深入，比如单词的表示从原始的 one-hot 编码方式到复杂的嵌入式词向量表示，这其中又包括从 word2vec^[17]到 glove 再到 bert，使得相应的词向量表示的信息更准确。Collobert^[8] 使用了基于 CNN-CRF 的深度学习框架进行通过无监督学习的方式从少量的文本中学习更多可获取的特征并将结果与基于统计的模型结果进行比较，对比通过无监督

的方法的结果与手工标注的方法的能力。近年来很多的工作都是基于 LSTM-CRF 结构，Lample^[9]提出的 LSTM-CRF 在英文领域具有极高的贡献，模型中通过 LSTM 得到输入文本的输出后使用 CRF 转换成相应的编码，在这基础上又相继提出的 Lattice LSTM^[10]模型以及 bert-CRF 等均表现出良好的效果。对于中文领域，由于目前的分词结果的不确定性，因此针对中文实体识别从两个部分出发，其一为以字为单位进行处理，其二为将输入序列使用分词工具进行分词然后输入模型处理。

文本摘要：文本摘要主要分为两大类：抽取式和生成式。基于抽取式的文本摘要言简意赅就是从原文中抽取关键词或者关键句的方式组成摘要。就目前而言抽取式的摘要主要是对句子进行打分排序从而根据分数进行选择或者是对句子进行二分类标注两种。最简单的抽取式方法是 Lead-3，方法提出者认为由于文章通常会在前几句就会透露出所要表达的具体内容，因此直接将前三句作为文章的摘要即可。在 pagerank 的基础上衍生出来的 TextRank^[18]方法通过计算句子的权重的方法选择其中得分最高的 K 个作为文本的摘要。与 TextRank 方法类似，基于无监督方法的 Padmakumar and Saran^[3]也采用将句子作为整体的方式，首先对句子进行编码得到句子的向量表示，然后使用 K-means 以及 Mean-Shift 方法对句子进行聚类，从而得到 N 个目标分类，在每个类别中选择距离中心点句子向量最近的句子作为该分类的摘要代表。虽然这种方法可以控制摘要句子的数量，但是 K 的大小需要受到一定条件的制约。近年来的研究主要是序列标注式摘要，序列标注主要方法为对原文中的句子进行二分类，在这种机制下摘要的结果就是对每一个句子进行二分类的过程。Nallapati^[4]就是通过对提高 ROUGE 分数的句子判定为摘要组成，否则抛弃的方式对句子进行标注。标注式文本摘要在某种意义上就是对句子进行分类的过程。除了标注式摘要，生成式摘要也逐渐成为研究重点。生成式摘要则是从词典中选择词语进行排序组合，也正是因为这个原因，需要通过学习来使生成的语句通顺，目前存在生成的摘要语义不明确，语句不通顺等问题。除了无监督方式以及序列标注另外一种研究是结合强化学习和 Seq2Seq 模型进行的改进。Zhang^[5]等在获得句子的序列概率分布间接的对句子进行打分之后，从中采摘出候选的摘要集合，将候选摘要集合替换序列标注来计算损失。此外，通过对句子排序的方式不同于对句子进行 0 和 1 两种二分类标签，而是对每一个句子进行评估其是否为摘要的概率，然后选出得分最高的 K 条句子作为最终结果，但是以往的先计算句子向量对句子打分然后根据分数选择的方法没有充分考虑句子之间的相互依赖，因此 Zhou^[20]等人将句子的评估标准改为收

益多少。除此之外，结合生成式和从原文复制方法也是一种研究思路，但是这种方法也存在连贯性低等问题，这种方法也存在优点，允许生成新的词汇。论文 *pointer-generator networks*^[12] 使用了 *coverage* 和 *copy* 机制，将 *seq2seq* 作为 *baseline model* 并结合了点状生成网络在一定程度上解决了 *OOV* 问题，其中 *coverage* 在一般的注意力机制上将历史的注意力信息添加到对当前注意力的生成上，若在某一时刻已经出现了较大的注意力向量，那么其后的注意力生成将会受到影响，其 *copy* 机制决定是从词典中生成还是从原文中复制。与命名实体识别一样，Liu^[6] 就使用生成对抗网络来产生摘要。除此之外，也有研究结合抽取式和生成式摘要来研究生成摘要，如 Li^[7] 使用了门控机制来选择需要的编码信息来最后的摘要生成，在此步骤之后继续使用门控机制从新的句子向量中选择有效的信息。*BertSum*^[19] 使用了目前较好的模型 *bert* 来获取句子向量提高模型的准确率，改模型还在每一个句子中加入了句子标注信息。*SeqGAN*^[2] 使用生成对抗神经网络生成文本摘要的代表之一，然而对抗神经网络存在较容易出现梯度缺失或者梯度爆炸问题。

金融文本处理：目前在金融文本上的研究主要是在网络评论文本上进行处理，其中文[21]对东方财富网上的发帖使用情感词典的方式性情感分析，并将分析结果结合市场因素等使用支持向量机进行风险预警。文[22]使用了 *word2vec* 和 *SO-PMI* 方法创建情感词典，使用情感混合模型进行情感分析。针对金融文本的实体识别文[23]针对金融文本中实体缩写和全称两种格式使用基于语法和条件随机场的方式进行识别，并使用模板迭代的实体关系抽取方式识别实体之间的联系。

1.1.3 研究意义

金融文本分析对研究市场经济走向以及个人和公司的投资指导有着重要的意义，通过对金融文本的研究可以降低投资者盲目投资的风险，对监督金融市场和监控股票的异常变动有重要的意义。目前依靠人力来进行公司经营情况的分析显然是无法完成的，对于专业的证券分析师等职业薪资水平较高，为降低市场分析的成本，降低人工进行分析的工作量提供一种解决途径。此外，本文针对文本摘要问题尝试了新的解决思路，在训练速度上有显著的提升。因此，针对金融文本的风险等分析研究将会在金融领域释放劳动力，减少股民和投资公司花费在资料分析上的时间与精力，为相关人员、企业与监管部门提供一定的决策支持。

1.2 金融文本风险界定及文本特点

金融文本包含的信息十分丰富，其类别有公司新闻（财务概况、重要事件、公司公告等）以及政策法规、社交评论等。金融文本风险分析的主要目标是辅助投资人员进行相关投资的分析，对海量数据进行摘要归纳来为投资研究人员提供信息减少其工作量。本文主要针对公告文本进行分析，公司公告是在相关部门监督下向社会公开公司重要事项的文书，公司公告一般会在社会上产生一定程度的影响，如上市公司的公告将影响股民的投资，其格式有一定的规范，但文本长度不一，部分文本的长度在 300 字以内，90%的公告文本长度在 2000 字以内，但是也存在公告文本长度超过 2 万字。

本文的风险分析与情感分析有所区别，因公告文本的正式性，其内部所含有的情感词语微乎其微，因此通过构建情感词典的方式来表述风险是不合适的。虽然目前也有对金融文本情感进行研究，但基本为对金融文本评论处理，因此本设计的风险定义为揭示公告文本所属的类型，并为每一个类型定义风险程度，通过判定公告所属的类型从而计算得到所指示的风险程度，概括为通过对公告进行分析，从而达到揭示公司的风险指数的目的。

1.3 论文组织结构

1.3.1 论文的主要工作

本课题在金融文本研究的基础上，采用深度学习方法完成命名实体工作、文本摘要生成工作、文本分类工作并对文本摘要所采用的模型提出了新的解决方案并在训练速度上得到提升。在工作的过程中学习使用了包括 Elasticsearch 和 OSS2 等多种工具。最终使用 Vue 前端框架和 Flask 后端框架完成了系统的可视化工作，具体工作表述如下：

（1）完成基于 Lattice LSTM 的深度学习模型编码工作，使用的框架为 Pytorch1.4、Tensorflow 2.1.0、Python 3.7，在 jieba 分词模型的基础上，该模型结合了基于字 LSTM 和基于词 LSTM 两种模型，能够更好的处理原本使用分词工具带来的分词错误引发的问题，将字的特征和词的特征相结合，能够更有效的发现文章中的隐藏特征。

（2）完成基于 Fasttext 的文本分类，由于 Fasttext 独特的优势，在取得与深度学习模型类似的效果的情况下具有更快的训练速度。此部分工作主要在数据处理、模型训练和结果后处理部分，在存储了千万条文本的 Elasticsearch 数据库中选择出合适的数据进行训练，由于目标类别数据一对多问题，因此从传统的 sigmoid 损失修改为

one-vs-all 损失，并训练了结余字和基于词的两种模型进行对比，由于一对多问题的目标标签个数是未知的，因此仅能通过使用阈值限定来进行标签个数的确定。由于目标标签中存在相似或者包含关系的标签，因此对完成的结果进行后处理来达到目标要求。

(3) 为了对文章进行简明扼要的概括，实现了基于 seq2seq、attention、coverage 的文本摘要生成模型，在使用 jieba 分词的基础上使用合适的停用词词典切分文章，然后通过 seq2seq 进行编码解码，并使用 attention 机制对 seq2seq 编码部分进行选择，在不同的阶段选择不同的输入内容，计算从词典中复制和从原文中复制的概率，使用 coverage 机制将每一个 attention 的历史数值添加到影响新产生的 attention 数值中去，从而在一定程度上面同一个词重复多次出现的问题。在实际使用中，发现该模型的训练和预测时间过于缓慢，因此提出了一种基于 transformer 的编码层，seq2seq 解码层，attention 机制以及 coverage 机制，在此修改上，将会有两次 attention，由于 transformer 更快的速度，目前模型速度为前面使用 seq2seq 的十倍左右。

(4) 完成基于 Flask 的后端以及基于 Vue 的前端设计。前端主要涉及 HTML5、javascript 编程语言，使用 js 和 Vue 完成框架的搭建，Vue 负责数据的渲染以及数据传输。在前端中使用 v-echart 将 lime 的分析结果使用柱状图的方式进行展示，使视觉效果更好。后端使用 Python，由 Flask 负责路由、数据传输等。

1.3.2 论文结构安排

本文共有五章，每个章节内容安排如下：第一章绪论。本章首先介绍风险分析系统的相关研究背景和研究意义，调研了风险分析系统的研究现状包括命名实体的研究现状以及文本摘要生成。此外包括了本次毕业设计的主要工作以及本地论文的主要结构安排。

第二章：本章主要介绍了风险分析系统的用户需求以及顶层设计，在这一章节将会主要介绍用户需求要求以及数据的流过程，从模块的层面上介绍数据的处理过程，介绍系统整体架构的设计方案以及每一模块将会使用的技术等。

第三章：本章内容将会详细介绍每一部分的实现过程即每一模块的实现过程，包括模型训练，训练数据准备等，包括金融文本类别判定模块、类别判定结果解释模块、命名实体识别模块、文本摘要模块等，此部分将会作为重点介绍。

第四章：本章将会对每一个模块给出使用效果图，依次介绍系统功能：命名实体

识别功能、文本类别判定功能、风险系数功能以及批量文件处理功能等并给出使用方法。

第五章：总结与展望，介绍了论文的工作并对系统中的不足地方进行讨论以及未来工作展望。

1.4 本章小结

在本章中，介绍了本文课题背景以及从命名实体识别领域和文本摘要两个领域来介绍目前的研究现状。为了对本文的工作进行阐述，在 1.2 节中介绍了本文的一些特征避免产生歧义，在 1.3 节中介绍了本文的主要工作内容以及本文的结构划分。

2 需求分析与系统设计

本章中给出了从系统存在的必要性，目标用户群体，用户群体的要求几个方面给出需求分析，继而根据需求分析确定系统的技术方案，确定系统的基本环境与使用技术，最后本章给出了系统的基本框架以及数据的基本流向。

2.1 需求分析

2.1.1 用户使用背景

目前，依赖人工手段来进行对海量的金融文本分析以及不切实际，目前如 APP “企业预警通”也仅仅对公司公告做了简单的分类，仍需要个人投资者或者企业投资分析师人工的去处理大量的文件，因此为了降低分析的难度，减少专业从业者的劳动力消耗，需能够对公告文件进行简要的描述，对文章主题进行概括并提取出文章涉及的实体，给出公告内容揭示风险。

2.1.2 预期数据处理类型

本系统目标处理的类型为公司公告文本。公司公告是一种具有一定格式要求的金融文本，其内容受到相关部门的监督保证其内容的真实性。通过对公告文本的分析可以得到公司在该时间段内发生的事件，得到事件涉及到的相关公司的实体，得以对公司前段时间的经营情况做出评价，对预期的股票走势或经营情况做出预测。对公告文本的分析面临如下难点。

第一、公司公告属于专业领域文本，具有一定的专业难度，其内容涉及到专业词汇，如若对公司公告进行分类需要考虑特定格式、特定词对类别的影响。

第二、公司公告长短不一，一般公告文本长度低于 2000 个字符，但是部分公告文本长度超过一万甚至两万字符，常规的深度学习网络对于过长的文本处理需要耗费大量资源。

第三、公告文件中涉及图表、图片等复杂图形，部分公司公告以 PDF 或者 word 文件存储，经过解析后的文本内容存在较大的噪音，文件中存在错误编码或者过多的标点符号等。

2.1.3 系统功能目标

(1) 对所提交的公告文本指出涉及的实体。

- (2) 能够针对文本的实体使用一句话简明扼要的概括。
- (3) 对公告所归属的风险类别给出提示并提示风险等级。
- (4) 对影响文本分类结果的原因给出分析。
- (5) 能够对文本进行批量的处理，符合大量数据处理的需求。

2.1.4 使用对象

系统的目标使用对象为股民、经济分析师、市场监管者。

系统对用户的要求应当为需要具有基本的计算机使用技巧以及基本的金融领域知识，能够对系统中涉及到的专业知识有一定的判断力，对公司公告类型有基本的了解，用户能够对系统给出的结果有自己的分析，用户能够根据系统分析结果对企业发展状况做出评价。

2.2 系统技术方案

C/S 架构由于可携带设备的普及在系统开发中占有率越来越高，但是 B/S 架构仍具有强大的生存能力且实用型更强，尤其是在这种架构下，可以在少量的改动下就可以移植到多种平台，并且与平台的依赖性不大，只需要做好适配便可以轻松使用，并且不需要过多的本地资源，因此，本项目将采用 B/S 架构，底层语言选择 Python。

本系统前端采用 vue 框架。Vue.js 是当前十分热门的 JavaScript MVVM 库，使用 Vue 不需要复杂的操纵 DOM，Vue 内部已经将 DOM 和数据绑定起来，如果数据改动相应的 DOM 也会自动的更新。根据官方测试的介绍 Vue 的渲染能力优于 react，因此反应速度迅速。鉴于 Vue 是中国人自己搭建的框架，官方中文文档清晰，官方网站以及教程、API 对国人都相较于其他框架更方便理解，并且其有强大的支持，对于开发者十分友好。由于 Vue 具有良好的生态环境，很容易将基于 Vue 的项目与以往其他框架项目进行合并。其包括声明式渲染、组件系统、客户端路由、大数据状态管理、构建工具等独立的功能和结构模块，可以根据需求选择进行配置，只需要使用自己需要的模块即可。除了文档工具，Vue 还具有大量的组件允许直接使用避免重复的构建已有的工具。

对于后端的设计本系统采用了 Flask 框架。Flask 是一门基于 Python 语言的后台开发工具，使用方法十分灵活，也正因为此 Flask 收到了广大开发者的喜爱。Flask 使用 Jinja2 模板引擎来提供网页解析以及 Werkzeug WSGI 服务来实现 python web 应用于 web 服务之间进行数据交互。Flask 相较于 Django 而言属于轻量级的 web 框架，

Flask 主要通过第三方的扩展来实现复杂的功能。Flask 包括三种模式：M（模型层）主要负责数据库建模处理；T（模板层）负责处理用户需要展示的内容；V（视图层），负责对用户的请求进行处理并对用户的请求做出相应。

因此本系统采用 Vue+Flask 作为前端以及后端的组织工具，系统中的关键的工具的版本和环境情况如下：

- （1）服务器：Win10 64bit 专业版
- （2）前端框架：Vue 2.6.11
- （3）后端框架：Flask 1.1.1
- （4）Pytorch：1.4.0
- （5）Tensorflow：2.1.0
- （6）Python：3.7
- （7）Cuda 10.1

其他要求：基本的 python 运行环境、Gpu 运行环境，内存需求>8G。

2.3 系统框架设计




图 2.1 系统架构

图 2.1 中 UI 部分编码语言设计 HTML5 以及 JavaScript，基本架构使用 CSS 创建，数据与组件使用 Vue 处理，数据的传输使用 Flask 的 WSGI 在前端和后端之间传输。将完本传输到后端后分别进行命名实体识别部分、风险判定部分、文本摘要部分、风险解释部分的处理。




图 2.2 数据流图

整个系统的输入为用户的文本输入，其中可以分为用户输入的单文本以及用户以文件的形式批量输入的文件，输出的类型也有两种，第一种就是将用户的单文本直接在 web 页面给用户展示，第二种则为将用户的结果以文件的形式批量的输出供用户参考。

在用户输入文本之后先将文本根据需求预处理其中根据目前的后面模块需求分为两种，第一种为存储为原始文本，第二种包括使用分词工具以及停用词等将文件存储为相应模块需要的格式。在经过相应的模块的处理之后将结果汇总并按照要求格式返回给用户供用户参考。

2.4 本章小结

本章小节中介绍了用户需求，其中列出了预期功能组成以及目标用户类型。在 2.2 节中详细的介绍了系统的前后端框架选择以及相应框架的优势，此外给出了本系统运行的环境。在 2.3 节中从系统框架图和系统数据流程图两个方面介绍了框架的模块，介绍了从用户输入数据到数据通过多个模块进行处理然后给传输到用户端以供用户进行显示。

3 系统模块实现

本章将介绍金融文本风险分析系统中主要功能模块的实现、包括其算法模型、数据准备、参数调整、以及后处理等内容，其中也简要的介绍了在模型中涉及到的一些相关知识。

3.1 基于 Lattice LSTM 的命名实体提取

LSTM 是循环神经网络 RNN 的变体，在普通的 RNN 结构中添加了隐藏层状态的输出。基于 LSTM-CRF 的实体识别分为两种，第一种为如图 3.1，基于字为单位做命名实体识别，在 LSTM 的输入为每一个字作为一个输入。但是此模型无法很好的利用语句中的序列信息和显性的词。




图 3.1 基于字的 LSTM 模型

基于词的 LSTM-CRF 模型需要提前将文本进行分词，然而，图 3.1 模型忽略了词的作用，而图 3.2 的模型却受到分词模型的分词准确性的制约，一个简单的例子就是当输入的句子容易造成歧义，那么分词模型的分词结果很容易出现问题，那么系统的实体识别部分就会收到错误的分词的影响，如“南京市长江大桥”是容易被划分为“南京市 长江 大桥”或者“南京市长 江大桥”，因此，使用基于词的模型在处理这个类型得文本上就会出现问题。鉴于此特点，本文选择了新的模型。




图 3.2 基于词的 LSTM 模型

本文采用的模型结构如图 3.3 所示，在这种结构中，使用了一个自动获取的大型词典来对句子中的词进行匹配，通过这种方法可以很好的避免不存在词格中的词。




图 3.3 Lattice LSTM 模型

如图 3.3 所示，与普通的 LSTM 模型不同，这里的（南京市）将会作为潜在的词语信息整合到 LSTM 中，其余主干中的相应 character Cell 连接。图中 $C_{1,3}^w$ 表示从索引 1 到索引 3 的隐藏状态，该 cell 没有输出门（因为此处不需要输出）。每一个时刻，系统考虑截至到该时刻的输入文本可能组成的短语作为潜在信息，如图 3.3 中的南京市即作为隐藏信息，对于潜在的信息中输入门的计算方式如下，与普通的 LSTM 相同。LSTM 相较于普通的 RNN 只有一个 h^t ，LSTM 有两个隐藏的状态，一个是 h^t ，另一个是 c^t ，其中 c^t 的变化速度较慢， h^t 的变化速度相较于更快，LSTM 中包含输入门、

输出门、遗忘门。其相应的为：忘记阶段主要是将上个节点传输进来的内容进行选择性忘记，忘记不需要的，记住需要的，其标记为 z^f ，对 c^{t-1} 选择忘记。选择性记忆则是对输入的 x^t 进行选择记忆，其表示方法为 z^i 。输出则是通过标志 z^o 控制，主要用于选择哪些被输出到外部，并且对上一阶段的 c^o 进行变换。

$$i_{b,e}^c = \sigma \left(w^{li} \begin{bmatrix} x_c^c \\ c_{b,e}^w \end{bmatrix} + b^l \right) \quad (3.1)$$

当如果有多个潜在的词组的时候那么就存在多个 i ，因此需要对其进行处理，计算公示如下：

$$c_j^c = \sum_{b \in \{b' | w_{b',j}^d \in \mathbb{D}\}} \alpha_{b,j}^c \odot c_{b,j}^w + \alpha_j^c \odot \tilde{c}_j^c \quad (3.2)$$

其中 $\alpha_{b,j}^c$ 和 α_j^c 是输入的归一化处理，其计算方式如下：

$$\alpha_{b,j}^c = \frac{\exp(i_{b',j}^c)}{\exp(i_j^c) + \sum_{b' \in \{b'' | w_{b'',j}^d \in \mathbb{D}\}} \exp(i_{b',j}^c)} \quad (3.3)$$

$$\alpha_j^c = \frac{\exp(i_j^c)}{\exp(i_j^c) + \sum_{b' \in \{b'' | w_{b'',j}^d \in \mathbb{D}\}} \exp(i_{b',j}^c)} \quad (3.4)$$

$c_{b,j}^w$ 的计算方式如下：

$$\begin{bmatrix} i_{b,e}^w \\ f_{b,e}^w \\ \tilde{c}_{b,e}^w \end{bmatrix} = \begin{bmatrix} \sigma \\ \sigma \\ \tanh \end{bmatrix} \left(w^{wt} \begin{bmatrix} x_{b,e}^w \\ h_b^c \end{bmatrix} + b^w \right) \quad (3.5)$$

$$c_{b,e}^w = f_{b,e}^w \odot c_b^c + i_{b,e}^w \odot \tilde{c}_{b,e}^w \quad (3.6)$$

式 3.6 中 x 和 c 分别代表输入的词向量和词汇的 cell state。例如前例中的“南京市长江大桥”当输入到“桥”的时候，那么不能仅仅的考虑来自“江”的输出，还需要考虑“长江大桥”和“大桥”两种潜在的词汇信息，之所以没有将“江大桥”作为潜在输入是因为词汇表中没有这个人名，因此不会将其作为潜在词汇。在此之后将此三种情况的输出做归一化处理即可得到选择后的词汇向量。此外其他的计算过程与普通的 LSTM 结构基本相同。

以上就是本模型的基本结构，为了对模型进行训练，这里采用了公开的训练数据集，因为类似模型对文本的领域敏感度较高，本文采用金融领域的数据集，这里对数据级进行简单的描述。命名实体识别中主要有三种标注方法，分别为“BIO”、“BIOES”，“BMES”。在 BMES 序列标注方法中，B 表示当前字符代表实体的开始标注，M 表

示当前字符位于实体的中间位置，E 表示当前词表示实体的结束，S 表示当前字符表示单独的词。BIO 标注体系方法中，B 表示当前字符指示实体的开始，I 表示当前字符指示实体结尾标注，O 表示当前字符不属于任何的类型的标注。BIOES 标注中 B 与其他方法相同表示实体开始，I 表示中间（内部），O 表示其他类型，E 表示实体的结尾，S 表示单独成为一个实体。本文的训练数据集采用的是 BMES 标注体系，数据集大小为 8 万余词。表 3.1 为数据集样例。

表 3.1 NER 训练集格式

上	海	浦	东	开	发	与
B-GPE	E-GPE	B-GPE	E-GPE	O	O	O
法	制	建	设	同	步	
O	O	O	O	O	O	
新	华	社	上	海		
B-ORG	M-ORG	E-ORG	B-GPE	E-GPE		

表 3.1 即为训练的基本格式，下面将会详细介绍命名实体识别部分各个模块。

数据格式处理：此部分包含将输入数据进行编码其中包括最大的处理文本长度，词向量长度、迭代次数、批处理的大小、是否使用预训练词向量等参数设置，此外词模块将会包含与训练的词典等数据。在训练过程中，此模块将会处理如下信息：

- （1） 将所有的标注类型进行存储并建立标注到索引以及索引到标注的映射。
- （2） 将所有的训练文本按照字、词进行索引到文本之间的相互映射。
- （3） 解析预训练词向量文件，存储预训练的向量信息。
- （4） 将文本与建立的词典匹配，将存在的短语从语句中提取出来。

词典模块：以简单的列表形式存储所有词典是一种好方法，然而并不能祈求在查表的时候顺序扫描整个词典，这样的速度显然不能满足系统的需求，因此，本系统采用一种树形结构，相同开头的短语将共用相同的开头，不同的部分则展开新的分支，通过这种方法，算法只需要递归的查找即可，直到查找结束或者查找失败，如图 3.4 所示。




图 3.4 词典存储格式

预训练模块：此部分是模型的编码，其又是多个子模块组成，其中 `bilstmcrf` 模块是模型的顶层封装，封装了 LSTM 和 CRF 两个子层，在 LSTM 子层中是由 Lattice LSTM 模块封装，在该模块中就是普通的 LSTM 门增加了新增加的潜在词语处理门，在这里需要进行前面介绍的对每一个潜在的词语进行归一化处理。

以上是命名实体模块的主要结构，经过训练后不仅获得了模型文件，同时也包含了 `data` 模块存储之后的词向量文件以及其他的预处理信息，系统在实际使用中将会调用这些信息并处理。在本文进行命名实体识别时，处理过程如下：




图 3.5 实体识别过程

如图 3.5 所示，输入数据将是一段文本，由于公告文本的特殊性，其实体一般都在文章前部以“某公司简称”等情况出现，因而对于过长的文本系统中将会进行截取。直接输入的文本不满足系统设计的要求，因此会将文本处理为单个字占据一行的文件，进过读取模型的相关参数并生成标注序列，就得到了文件的标注序列，在得到标注序列后还需要对标注序列进行解析，转换成相应的实体编码即可。

图 3.6 给出了文本分类准确率随着迭代次数变化的过程，由实验结果可知：在金融文本上的训练准确率可以达到 0.96，测试准确率最高也可以达到 0.94，可以正确识别多种实体。




图 3.6 准确率变化表

3.2 基于 fasttext 的文本风险等级确定

在风险等级分析模块，系统通过对公告文本进行多标签分类，为其赋予风险等级，将文本对应的风险等级加权和处理即得到最终风险等级。

3.2.1 公告类别确定

本文所采用的公告文本属于多标签文本，这和多分类问题不同，多分类问题是相较于二分类问题，二分类对应的是只有两种类别，多分类意味着类别超过两种。多标签问题是指一对多问题，也就是对于一个对象可能有多个分类，一般比较常见的是新闻分类，如一篇报道可能既属于娱乐新闻又同时属于财经类新闻，一般多标签问题的标签数目超过两种。

由于目前没有公开的数据表明公告的类别数目，因此，首先需要确定公告的类别，这里系统参考企业预警通等应用的类别并参考已有的一些知识暂定了类别的数目，因而首先需要确定标签的类别。

本文依赖于已经从各大公开平台下载的公司公告文件解析的文本。目前可用文本约两千万条，才用的是公告标题和公告正文分开存储的机制。公告标题和公告正文分别存储在 Elasticsearch 和 OSS 数据库中，两者之间通过索引进行对应。

ElasticSearch 是一个基于 Lucene 的搜索服务器，提供了一个基于 RESTful 的 web 接口，由于其提供分布式的多用户全文搜索，因此能够达到实时，稳定，可靠的提供，每个字段都可以被索引并被搜索。目前不需要对公告正文有过高的访问需求，使用 OSS 存储海量数据降低了存储成本。根据阿里云官网介绍，OSS 的可用性不低于 0.99995。Elasticsearch 中包含公告发布时间、发布部门、来源、公告标题、公告 ID 等信息，OSS 中仅包含公告 ID 和公告正文。

系统使用 K-means 聚类对含有“公司”、“公告”的标题进行聚类，之所以要进行筛选是因为原始的千万条数据包含较多噪音，为了提高效果因而需要进行筛选。具体筛选过程如下：首先将标题转换为词向量，然后转换为句子向量继而进行聚类，最终确定风险类别 232 类。简单的通过标题筛选必然不能满足系统的需求，这里只是为了选择训练数据。在确定了公告类别后系统依照聚类结果和规则相结合的方式对标题筛选，部分规则如表 3.2 所示。

表 3.2 部分风险类别规则

风险类型	筛选规则	筛选方法
重大事项	重大 重要，不含受托管理事务	规则
非标准意见	非标准意见	规则
变更偿还借款对象	变&偿还借款对象	规则
实控人变更	（实际控制人 实控人）&变,不含未 没 不	规则
变更法定代表人	变&法定代表人,不含未 没 不	规则+聚类

通过使用表 3.2 的规则从 ElasticSearch 数据库中提取标题数据。通过使用基于规则的方法将所有的标题进行分类，得到分类结果。经过系统训练数据的筛选，发现部分标签没有对应的数据，这可能和所选择的数据筛选方法有关，经过对筛选规则的修改，或者删除不是十分必要的标签，最终确定了现有的标签数量为 205 个。

针对如何对公告文件进行分类问题，系统采用了谷歌公司在 2016 年开源的用于生成词向量和进行文本分类的工具 fasttext^[12]。由于硬件资源环境有限，难以采用复杂的深度学习模型对公告全文本进行训练，这里对公告的长度进行了分析统计如图 3.7，而 fasttext 虽然是浅层神经网络但是其训练结果却能不逊色于深度神经网络，这是本文选择 fasttext 的重要原因。Fasttext 能够在海量数据上快速处理的原因之一便

是因为使用了分层的 softmax 机制,这个机制和 word2vec 的 CBOW 类似,分层 softmax 目的是利用树形结构来降低搜索的次数,这样在计算 $P(y=j)$ 的时候不用注意无关的节点,只需要计算一条节点。关于树结构的建立,fasttext 采用的是哈夫曼树,所




图 3.7 公告文本长度分布

有的类别在哈夫曼中用叶子结点表示,从根结点到叶结点所形成的路径就是为一种可能。那么计算这种出现的概率 $P(y_i)$ 表示方法为:

$$P(y_i) = \prod_{l=1}^{L(y_i)-1} \sigma(\llbracket n(y_i, l+1) = LC(n(y_i, l)) \rrbracket) \cdot \theta_{n(y_i, l)}^T X \quad (3.7)$$

其中 $\sigma(\cdot)$ 是 sigmoid 函数, $LC(n)$ 为节点 n 的左子树, θ 表示相应根节点的参数, $\llbracket x \rrbracket$ 函数定义为:

$$\llbracket x \rrbracket = \begin{cases} 1 & \text{if } x == \text{true} \\ -1 & \text{otherwise} \end{cases} \quad (3.8)$$

通过使用分层的 softmax 机制,将算法的时间复杂度从 $|k|$ 降到了 $\log |k|$ 。对于训练词向量问题,那么每一个节点将代表一个词向量。同时由于其使用了字符级别的 n-gram,虽然对于中文无法将字符拆分。但是对于 n-gram 算法,可以区分部分词语的顺序特征,如“我爱你”和“你爱我”在使用一元语法模型的时候是没有区别的,因为对于一元语法,只会记录其是否出现,但是当选用 2-gram 的时候“爱你”和“你爱”就可以轻松的区分开来。在 TF-IDF 方法中,通常会过滤掉词频过低的词语,如

果需要为了提升速度可以选择将出现频率低的文本筛除。Fasttext 模型的基本框架如图 3.8 所示，fasttext 模型只有输入层、隐藏层、输出层三层，这里的输入数据 X 已经是经过训练之后的词向量，如果系统使用预训练的词向量，那么在 fasttext 进行文本分类的过程中将不会产生向量文本，否则只要不输入预训练的词向量，在训练的过程中将会产生词向量文件。对于文本分类模型，哈夫曼树的叶子结点就是文本的类型，这一点和 word2vec 模型的 CBOW 类型相同，事实上在 fasttext 进行词向量训练的过程中也可以选择和 word2vec 模型相同的 CBOW 类型或者 skip-gram 类型。




图 3.8 fasttext 模型结构

针对如何使用 fasttext 进行训练，这里进行了多次尝试，其中主要分为两大类，在前面已经讨论过，使用分词工具进行分词会造成数据原本的错误，这是因为分词本身就是不确定的，因此本文讨论了基于使用分词工具的模型和直接用单个 token 为输入的两种方式。针对分词工具，目前有多种工具供选择，包括 THULAC、jiebaLTP、ICTCLAC、HanLP 等，此外还有百度 NLP、腾讯文智、阿里云 NLP 等商业分词工具，jieba 分词是使用较为广泛的一种。除此之外，针对于一个真实文本，是不可能和在实验室里用到经过清洗的文本一样，因此本文讨论了清洗的方式，需要注意的点如下：

- (1) 是否应该去除标点符号；
- (2) 是否应该去除数字；
- (3) 是否应该去除英文字母。

其中第三点是否应该去除英文字母需要着重讨论，标点符号一般都会被清洗，至于数字对于大多数的文本都是应该去除，但是本系统中存在“低于百分之十”、“高于百分之三十”之类的标签，因此如果去除数字可能会导致对于这些相似的文本的分类结果无法区分，系统最终选择保留这类数字。由于公告文本很多是从 PDF 文件中解

析出来,其中可能存在图表等图形,因此里面存在解析错误导致的乱码字符以及字母等,但是其中也包含网址信息等,致使在实际训练的过程中这部分经过较多的讨论,最终确定由于本系统目前针对的是中文公告因此英文部分在最终结果的判定上没有什么影响。经过上面的文本长度分析得知部分文本长度较长,在此情况下 Fasttext 训




图 3.9 基于分词的 fasttext 分类精度

练集的大小从八万条数据到十二万条、二十万条最终为四十万条数据,经过多种调整,基于分词的文本分类精度最终达到 0.95。

除此之外,也对基于 word 和基于 token 的两种模型进行了讨论,其精度和召回率如下表所示。

表 3.3 两种模型的测试结果

模型	Precision	Recall
Based word	0.951	0.922
Based token	0.931	0.932

3.2.2 公告风险系数确定

至此已经完成对公告文本的分类处理,仍需要将确定公告的风险系数,本文将每一个类别根据其风险类别给定了一个在 0 至 1 之间的小数表示其风险等级,其中数值 0 表示情况良好,数值 1 表示风险等级极高,有严重的风险。

表 3.4 风险系数对照表

类别	风险系数
发生重大变化致不符合公司债券上市条件	1.0
注销许可证	1.0
问询函	0.6
设立分公司、子公司	0.2

前面已经讨论过，本文采用的公告文本的分类是多标签问题，一个文本可能对应多个标签，至于标签的数量，本文采用阈值的方法来进行判断，阈值的确定在验证集上取得最高精确度为准，因此，在多标签的情况下，本文将多个标签的风险系数取平均值的方式作为最终的风险系数。

3.3 文本摘要生成及改进

文本摘要有多种实现方式，本模型将会涉及 attention 机制、coverage 机制以及 seq2seq 模型。Seq2seq 模型最早提出于 2014 年，该模型提出的时候应用的场景是机器翻译。整个模型基于 LSTM，LSTM 在前面已经简单介绍，模型分为两个部分 encoder 层和 decoder 层，编码层的结果将会输出一个句子的向量，然后解码层将该输出作为输入并开始预测输出，直到达到指定的长度或者结束标志。Seq2seq 的目标为：

$$p(y|x) = \prod_{t=1}^{n_y} p(y_t|y_1, y_2, \dots, y_{t-1}, x) \quad (3.9)$$

上式可以解释为在解码层的某一时刻的结果的概率是由当前输入和以往的解码结果决定的，编码阶段当前时刻的隐藏层状态是由上一时刻的状态和当前时刻的输入决定的。Seq2seq 模型有多种解决方式包括将编码层得到的语义向量直接作为解码层的 h_0 输入到 h_1 、随机初始化 h_0 将编码层的输出作为解码层各阶段的输入以及随机初始化 h_0 状态，将编码层的编码向量和前一时刻的隐藏层输出作为当前时刻的输入三种方式。在第三种模型上由于解码层的输入包含前一时刻的输出结果 y ，在 y 为错误的时候就会对后面的结果产生影响，简单来说就是一错再错。为了得到更好的结果，一种解决方式为选择一定比例的将预期结果作为前一层的输出直接输入当前时刻。

Attention 机制是为了解决编码层中仅仅使用一个语义向量难以较好的表示语句的含义以及当输入的语句较长的时候容易出现梯度消失等问题，因此参考人类在看

书的时候会注重其中一些词的特点提出了 Attention 机制。Attention 机制在解码阶段的不同时刻会注意到不同的词语。在此情况下，解码层的每一时刻的输入不必须要单一的语义来表示而是当前时刻得到的注意力向量。注意力向量的计算方式为将解码层的某一时刻的前一时刻 h_{t-1} 的隐藏层输出与每一时刻隐藏层输出计算相关性，至于相关性的计算有多种解决方式。

$$a(h'_{t-1}, h_i) = h_i^T h'_{t-1} \quad (3.10)$$

$$a(h'_{t-1}, h_i) = h_i^T W h'_{t-1} \quad (3.11)$$

$$a(h'_{t-1}, h_i) = \tanh(W_1 h_i + W_2 h'_{t-1}) \quad (3.12)$$

使用上述方法获得相关向量后，需要进行归一化处理，一般的归一化方式为 softmax，得到归一化向量之后即可融合编码层的输出作为解码层的输入。

$$a_{ti} = \frac{\exp(e_{ti})}{\sum_{j=1}^N \exp(a_{tj})} \quad (3.13)$$

$$c_t = \sum_{i=1}^N a_{ti} h_i \quad (3.14)$$

在测试过程中为了得到更好的结果，算法并不是只选择一个输出结果，而是将词典中最高的几个词语作为下一时刻的输入，下一时刻将分别对这几个词语计算预期输出然后选择其中最高的即可词语作为接下来时刻的输入。本文采用的模型为基于 baseline seq2seq 模型和点生成网络的模型，模型结构如图 3.10。




图 3.10 Pointer-Generator Network 模型

前面已经介绍过 attention 相关参数的计算方法，本文采用的是计算方法三，LSTM 选择的是双向 LSTM，在经过注意力权重和相应的隐藏层输出计算加权和之后得到当前时刻的解码层输入向量 $\hat{h}_t^*$ ，在此基础上通过如下方式计算得到单词表 P_{vocab} 的概率分布。

$$P_{vocab} = \text{softmax} \left(V' \left(V \left[S_t, \hat{h}_t^* \right] + b \right) + b' \right) \quad (3.15)$$

通过上式得到了词典的概率分布，根据概率分布即可得到需要的输出词。这便是普通的 baseline 模型的计算过程，为了衡量是从原文中复制还是从词典中摘取，引入了图 3.10 中的 P_{gen} 变量，关于 P_{gen} 的计算方式，需要用到解码层的 s_t 和经过注意力机制计算之后的向量 $\hat{h}_t^*$ 以及输入。

$$p_{gen} = \sigma \left(w_h^t \hat{h}_t^* + w_s^T s_t + w_x^T x_t + b_{ptr} \right) \quad (3.16)$$

在得到上面的生成结果之后使用点状网络，点状网络的作用是在一系列点中找到几个点能包含全部点。

$$p(w) = p_{gen} P_{vocab}(w) + (1 - p_{gen}) \sum_{i:w_i=w} a_i^t \quad (3.17)$$

在上式中 $P_{vocab}(w)$ 表示前面生成的词语出现的概率， a_i^t 表示原文中的词的概。如果表示从文档中复制那么前半部分的值应为 0，如果表示出现在常规的词表中那么后半部分的值应该为 0。

通过上面的方法得到的结果可能会出现词语重复出现的情况，因此这里的 coverage 机制的目的就是尽量减少重复出现的概率，其原理是将已经计算过的注意力向量添加到影响后面注意力向量的生成中。其计算过程如下：

$$e_i^t = v^T \tanh(W_h h_i + W_s s_t + w_c c_i^t + b_{attn}) \quad (3.18)$$

$$c^t = \sum_{t'}^{t-1} a^{t'} \quad (3.19)$$

通过这种方法如果某一个词在前面已经出现过较大的注意力，那么后面出现的概率就会降低。

系统选用的数据全部都是真实的公告文本，由于缺少标注数据，本文采用的摘要来自经过筛选的公告标题。目前文本摘要的 rouge2 分数达到 0.84。但是由于本模型双层 LSTM 等原因，算法训练速度过慢，这也同样影响到预测阶段的生成速度。故参考了 Transformer，transformer 是第一个全部使用 attention 机制搭建的模型，其

计算速度更快，这里将 transformer 的编码层替换前面介绍的 LSTM 编码层。编码层是由六个一模一样的子层组成，每一个子层首先是 self-attention 机制，self-attention 中每个词对应三个向量 Q、K、V，他们是输入的词向量乘以不同的权重矩阵从而得到的，将某一个 Q 和其他词的 k 向量进行点乘，得到分数使用 softmax 进行归一化，将得到的分数与相应的 V 计算得到加权和 Z。transformer 中使用了多头注意力机制，其本质为使用了多个 self-attention 机制，将每一个 self-attention 得到的向量 Z 进行拼接则得到一个更大的向量矩阵，经过全连接层的处理就得到了向量 Z。为了增加模型捕捉序列中循序的能力，一般有两种处理方式，第一种就是模型自己学习，第二种则为在嵌入式词向量中添加位置信息，transformer 采用的是第二种编码方式，对每一个输入的嵌入式词向量添加编码信息，根据其出现的位置不同，分为两种不同的位置编码方式：

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000 \frac{2i}{d_{model}}}\right) \quad (3.20)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000 \frac{2i + 1}{d_{model}}}\right) \quad (3.21)$$

上式中 d_{model} 为模型参数，通过这种计算，即可将文本序列中的绝对位置和相对位置添加到编码当中去。为了降低梯度爆炸和梯度消失等问题的概率，在 self-attention 之后添加了残差链接处理（图 3.12 虚线部分），处理方式输入 x 的非线性处理之后与原输入 x 相加。后面的 feed Back 则为前向神经网络。




图 3.11 基于 transformer 编码层的实现




图 3.12 transformer 编码层

经过上述的处理,文本摘要模型目前的 rouge 分数为 0.65,通过变换为 transformer 的 encoder 层,所改进的模型的速度有了极大的提升,速度提升了十倍左右,此模型大大缩短了处理时间。下面是此模型对公告文本的一个生成参考的示例:

泰山 石油 石油 石油 股份有限公司 监事会 决议 公告 2003 - 07 - 1506 股份有限公司 第四届 监事会 第六次 会议 公告

由示例结果可知:虽然仍存在重复出现的词的问题,但是公告文章的基本信息包括时间、时间、实体均已能够正确的获得。

3.4 基于 lime 的结果解释

仅给出系统对文本的分类结果以及风险等级是一个过于黑盒的操作,这种做法很容易让人对结果产生质疑,因此,为了对结果进行简单验证,采用了 lime 方法对影响分类结果的短语进行分析,对结果进行解释。

近年来有很多算法都对分类模型进行了解释,而且全都是黑盒的解释,也就是说适用于多种结构的模型,因此使用性很强。对于批量的文本通常可以使用准确率等指标对模型进行评价,而 lime 可以对某一个样本的重要特征进行提取,重要的是 lime 解析出来的是人类可以理解的特征而不是参数特征。其做法是在某一个样本上得到结果及其概率后选择这个样本附近的点来训练模型拟合选择的点,虽然这样在全部的数据集中没有效果,但是在这几个数据点上是有用的,lime 认为要做的也就是在这几个样本上可用即可。算法的基本流程就是遍历 N 次来生成 N 个不同的样本,这

些样本在距离上与原来版本相近，比如说对于训练样本“一食堂好吃”，则可能会生成“二食堂好吃”，“一食堂”等相近的样本，然后使用模型将结果标签和其相应的概率和样本组合到一起，最后使用 Lasso 来训练一个岭回归和线性回归的相对更简单的模型，这样就可以获得相应的特征的权重，这些特征就是人类可以看懂的特征。对于图形来讲，就是将其分割成更小的图片块来进行分析。

为了能够让 lime 对训练数据进行处理，需要对 fasttext 输出的结果进行调整，在 fasttext 中的输出为已经根据阈值 k 进行调整，输出的结果是按照从高到低的顺序输出了满足阈值的标签，为了实现数据的对齐需要将 fasttext 得到的类别-概率词典映射为固定顺序，这样就得到了 lime 要求的输入。目前本系统已经能够展示良好的效果，例如对于测试文本其对应的概率是“增持股份”，经过训练后，可得到影响因素如表 3.5 所示。

表 3.5 lime 影响因素分析样例

文本	权重	文本	权重
增持	0.5922	股份	0.1380
的	0.0652	公司	0.0506
南方	-0.0379	本次	-0.0332

表 3.5 中权重为正的表示对结果产生正的影响，权重为负表示对结果的影响为负的影响，权重的绝对值越大对结果的影响越大，分析结果表明：lime 对找到了“增持股份”标签的主要影响因素。

3.5 本章小结

本章详细介绍了风险分析系统中后端的几个主要模块，包括命名实体识别模块、文本风险等级确定模块（其中包括文本公告所属的类别判定以及类别对应的风险映射）、文本摘要生成模块以及为了满足系统需求尝试进行的修改、最后介绍了基于 lime 的对文本公告所属类别分类的影响因子确定。

4 系统功能与测试

本章将介绍风险分析系统主要功能和相应的测试案例。介绍并展示实体识别模块功能、摘要生成功能、文本类别判定与风险确定功能、风险判定原因解释功能、文件批量处理功能，并对系统介绍的功能提供测试案例展示。

4.1 实体识别模块

实体识别模块是风险分析的主要功能之一，虽然对于公告文本来说在获取公告文件的时候已经存储公告的发布者，但是在存储的时候是没有将文章中所有的实体都进行保存，因此为了更好的找出关联实体，有必要进行实体识别。

整个页面包含七个主要部分：（1）文件上传按钮，上传文本文件，（2）下载按钮，将上传之后的文件处理之后进行下载，（3）文本输入框，这里支持输入单个文本进行分析，（4）类别分析，此处用于显示文本的类别以及识别到的实体，（5）文本摘要，此处将显示生成的文本摘要，（6）风险类型，这里通过进度条的方式显示风险程度。（7）影响分类结果因素。

在文本输入框中粘贴需要分析的内容然后回车即可得到对文本分析的实体内容，这里如图 4.1 部分（4）所示包含海南海药股份有限公司、深圳市南方同正投资有限公司以及深圳证券交易所。




图 4.1 前端展示页面

4.2 摘要生成

这里是将类别分析和文本摘要两部分结果放在了同一个文本域中，默认显示的是类别分析中的内容，如果需要展示文本摘要的结果则需要点击文本摘要按钮，在下面的文本域中将会展示文本摘要的结果。鉴于即使使用了 **coverage** 机制，仍然存在出现重复词的现象，本文对输出结果进行了一个后处理，参考在真实的摘要文本中这种现象很少会出现连续重复词的情况，本文将连续重复出现的文本只保留一个输出，结果展示如图 4.2 所示。




图 4.2 文本摘要结果

如图 4.2 所示，系统的摘要结果符合系统的预期要求，甚至包含了公司实体名称以及“(更新后)”这个关键信息。

4.3 文本类别与风险等级

前面已经介绍了系统风险等级确定的方法，这里就不再赘述，系统除了展示风险等级之外，还给出了公告所属的类别，这里在类别分析模块的实体列表之后展示，如图 4.3，本文给出的测试文本并非训练数据集中的数据而是生文本，此处使用的文本已经被去除了标点符号，即使是带标点符号不会产生影响。




图 4.3 类别判定结果以及风险结果

从图 4.3 中可见，系统给出的预测类别与测试文本的预期标签“增持股份”相符，此处示例中只有一个类别，故风险等级仅由这一个类别决定。这里风险等级当鼠标放在上面即可显示风险系数，此处无法展示。

4.4 风险原因解释

风险原因解释模块的展示就是前文中介绍的系统展示的第七部分，如图 4.4 所示。




图 4.4 风险影响因素

对预测结果有积极影响的在右半部分表示为正数，产生消极影响的在左侧表示为负数，在图 4.4 中可以明显的看到“增持”、“股份”对最终结果影响最大，恰好满足系统预期结果。

4.5 批量文件处理

实际使用中遇到的可能很多都是对文件的批量处理，因此批量文本处理是一个很重要的功能。本系统设计为确认选择文件及完成文件上传，选择文件状态如图

4.5 所示:




图 4.5 上传文件样式

图 4.6 为服务器文件列表，其中文件 myupload.txt 为上传的文件，myupload.txt 为生成的结果文件，图 4.7 为结果文件，在结果文件中由于长度因素仅展示了摘要以及风险类别。

Mode	LastWriteTime	Length	Name
d-----			myupload.res
-a-----		2047989	1588402136.pdf
-a-----		2047989	1588404888.pdf
-a-----		2047989	1588496668.pdf
-a-----		1984	myupload.tmp
-a-----		2087	myupload.txt

图 4.6 服务器端文件列表




图 4.7 下载本地文件结果

4.6 本章小结

本章详细的介绍了系统中的各个功能的使用方法，并给出了相应的测试示例，尤其是基于 lime 的结果解释模块，系统使用了基于 v-chart 的柱状图来现实，具有良好的感官效果，能够直观的展示影响结果的因素，可以对预测结果的正误做出基本的判断。经过测试，风险分析系统满足需求分析时的基本要求，能够对公告文本做出良好的分析。

5 总结与展望

5.1 工作总结

随着网络时代的发展以及自媒体的欣欣向荣，网络文本正以铺天盖地的姿态出现，为了对这些文本进行处理必须使用计算机科学的方法进行分析，因此，NLP 将会有良好的发展前景。而金融领域文本由于其原本具有过多的专业信息因此目前也正有愈来愈多的研究正在进行，通过金融文本的研究可以对经济形势有很好的监控、预警，降低金融领域专业人员的工作难度与工作压力，同时也能够让更多的经济投资者不再盲目的投身到经济泡沫之中。

本文主要是对公司公告文本进行分析、包括命名实体识别、文本类别分类、文本摘要生成以及文本类别解释。系统首先对输入的公告文本提取涉及的实体，然后将公告正文根据对公告文本标题聚类获取的 203 种类别进行多标签分类得到每一个公告文本的类别，每一个类别都对应一个风险等级，对某一篇公告的所有风险等级计算加权和即可得出公告对应的风险等级。为了验证所涉及的分类型算法的分类效果，使用了 lime 提取对文本中对公告类别影响较大的短语。为了方便专业人员进行结果校验，解决部分公告标题缺失的问题，使用 pointer-generator 进行文本摘要生成。为了解决基于 LSTM 的编码层的速度较慢的问题，尝试使用 transformer 的编码层代替 LSTM，并取得了速度上很大的提升，相较于 LSTM 的模型速度提升了十倍左右。

在 UI 方面，采用的框架都是开发环境有好的框架，尤其是 flask 后端就是使用 python 处理，flask 框架是由各个框架组成，可以根据系统的需求进行配置，在系统不需要复杂的功能的时候可以忽略不需要的模块配置。前端使用 Vue 框架，此框架避免了开发者使用 javascript 控制 DOM，对于小白十分的友好。Vue 框架是中国人开发，开发者文档等配置以中文为主，一应俱全，通过 Vue 的高层封装开发者可以轻易地实现数据与元素的绑定，不需要手动的渲染更新数据。与 Flask 相同，Vue 有丰富的组件如本系统用到的 v-chart 就是在 Echart 上进行的封装，通过封装之后操作更加简单，只需要将数据添加到相应的 Vue 实例中即可。

除了前面详细介绍的各个功能模块的详细工作之外，在整个工作过程中还学习到其他系统知识。在 3.2 节提到了用到的训练数据集是真实公司的公告文本，没有被进行过筛选，这样得到的模型才能更符合实际，这些海量的数据都存储在 Elasticsearch 和 oss 数据库中，因此在整个工作过程中还涉及到这些数据库的使用。

由于系统采用的数据存储阿里云，如果将数据再传输到本地那么将会占据外网带宽等，因此整个训练过程在服务器端进行，因此在此过程中学会了服务器端的环境多版本控制以及基本的使用技巧等。

5.2 工作展望

本文中实现的风险分析系统实现了命名实体识别、公告风险级别确定、公告风险解释、文本摘要等工作，具有良好的实际意义，但是一个更为完善的风险分析系统有更复杂的功能，因而还有值得改进、调整之处，在此简明扼要的介绍。

（1）目前本文中实现的分析系统仍需要人工输入公告文本或者文本文件，未来系统的目标是能够实时的爬取数据公告文本。因为爬取获取的公告多以文件形式包括文本文件，word 文件、PDF 文件等格式，文件中又可能包含表格、图片等信息，因此这一部分仍需要大量的工作进行处理。在爬取并解析文件之后经过系统的处理可以按照公告类别分类、按照公司名称分类，可得到某一个公司的经营变化情况。

（2）目前对于所有的公告都认为其类别都属于聚类结果的 203 类公告分类之中，但是实际中仍然存在部分公告不属于 203 类公告，在本文的模型中，fasttext 对文本的预测仍存在部分文本结果远低于系统设定的阈值，针对这个问题需要对现有的类别需要修改还是确定一个“其他”类别现在尚无明确的方案。因此在后面的工作中需要对这种情况进行处理。

（3）目前系统的命名实体识别模块由于需要编码过多的文本，因此速度相较于其他模块较慢，此外由于模型的问题，对于文本长度敏感，对于较长的文本只能对文章内容进行截取，虽然对于公告而言，由于其格式的规范化要求，在文本的前面就会出现公司的相关名称，对于目前的系统影响不大，但为了适应更多的场景，后面将会考虑使用 bert-crf 进行解决。系统目前还存在无法处理获取实体之间的关系等问题。

参考文献

- [1] Hai Zhao, Chunyu Kit. Unsupervised Segmentation Helps Supervised Learning of Character Tagging for Word Segmentation and Named Entity Recognition[C]. In: *Proceedings of the Sixth SIGHAN Workshop on Chinese Language Processing*, SIGHAN: IJCNLP, 2008, pp. 106-111.
- [2] Lantao Yu, Weinan Zhang, Jun Wang. SeqGAN: Sequence Generative Adversarial Nets with Policy Gradient[C]. In: *Proceedings of The Thirty-First AAAI Conference on Artificial Intelligence*, Palo Alto, CA: AAAI Press, 2017, pp. 2852-2858.
- [3] Aishwarya Padmakumar, Akanksha Saran. Unsupervised text summarization using sentence embeddings[C]. 2016, pp. 1-9.
- [4] Ramesh Nallapati, Feifei Zhai, Bowen Zhou. A recurrent neural network based sequence model for extractive summarization of documents[C]. In: *Proceedings of Thirty-First AAAI Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2017, pp. 3075-3081.
- [5] Lantao Yu, Weinan Zhang, Jun Wang. Seqgan. Sequence generative adversarial nets with policy gradient[C]. In: *Proceedings of Thirty-First AAAI Conference on Artificial Intelligence*, PALO ALTO: AAAI. 2017, pp. 2852-2858.
- [6] Linqing Liu, Yao Lu, Min Yang. Generative adversarial network for abstractive text summarization[C]. In: *Proceedings of Thirty-Second AAAI Conference on Artificial Intelligence*, PALO ALTO: AAAI. 2018, pp. 8109-8110.
- [7] Wei Li, Xinyan Xiao, Yajuan Lyu. Improving neural abstractive document summarization with explicit information selection modeling[C]. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, Brussels, Belgium: SIGDAT. 2018b, pp. 1787-1796.
- [8] Ronan Collobert, Jason Weston, Leon Bottou. Natural language processing (almost) from scratch[C]. In: *Journal of Machine Learning Research*, BROOKLINE: MIT PRESS. 2011, pp. 12: 2493-2537.
- [9] Guillaume Lample, Miguel Ballesteros, Sandeep Subramanian. Neural architectures for named entity recognition[C]. In: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Germany: NAACL-HLT. 2016, pp. 260-270.
- [10] TURNER Peter D. Thumbs up or thumbs down? semantic orientation applied to unsupervised classification of reviews[C]. In: *Proceedings of the 40th Annual Meeting*

- on Association for Computational Linguistics, Philadelphia: ACL. 2002, pp. 417-424.
- [11] Joulin Armand, Grave Edouard, Bojanowski. Bag of tricks for efficient text classification[C]. In: *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics*, Valencia, Spain: EACL. 2017, pp. 427-431.
- [12] Abigail See, Peter J. Liu, Christopher D. Manning. Get to the point: Summarization with pointer-generator networks[C]. In: *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics*, STROUDSBURG, PA: ACL. 2017, pp. 1073–1083.
- [13] Google Scholar, <http://scholar.google.com>.
- [14] Vue, <https://cn.vuejs.org/index.html>.
- [15] Flask, <https://flask.palletsprojects.com/en/1.1.x/>.
- [16] Marco Tulio Ribeiro, Sameer Singh, Carlos Guestrin. "Why Should I Trust You?": Explaining the Predictions of Any Classifier[C]. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, NEW YORK, NY: ACM. 2016, pp. 1135-1144.
- [17] Tomas Mikolov, Ilya Sutskever, Kai Chen, GregCorrado, and Jeffrey Dean. 2013b. Distributed representations of words and phrases and their compositionality[C]. In: *Proceedings of 27th Annual Conference on Neural Information Processing Systems, (NIPS) 2013*, pp. 3111–3119.
- [18] Mihalcea R, Tarau P. TextRank: Bringing order into text[C]. In: *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Barcelona, Spain: SIGDAT. 2004, pp. 404-411.
- [19] Liu Yang. Fine-tune BERT for Extractive Summarization[J]. arXiv, 2019.
- [20] Qingyu Zhou, Nan Yang, Furu Wei. Neural document summarization by jointly learning to score and select sentences[C]. In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, Melbourne, Australia: ACL. 2018, pp. 654-663.
- [21] 路明慧. 基于网络文本挖掘的投资者情绪对股票市场风险的预警研究[D]. 江苏大学, 2019.
- [22] 姚明超. 基于主题模型的金融论坛文本挖掘[D]. 浙江工业大学, 2019.
- [23] 王树伟. 面向金融文本的实体识别与关系抽取研究[D]. 哈尔滨工业大学, 2014.

致谢

时光荏苒，光阴似箭，四年的时间转瞬即逝，当年满怀期待步入合肥工业大学校门仍历历在目。今临毕业，尚未能够和母校、老师、同学告别不禁唏嘘不已、感慨万千。犹记当然之志，今日仍在逐梦路上，很幸运路上有谆谆教导的老师、团结友善的同学、默默付出的父母、亲人。

感谢合肥工业大学，为我们提供了良好的学习环境，教学楼的星星灯火是无数学子最好的记忆，三尺讲台是所有老师的坚守，学校的保研制度为所有学生提供更高的舞台，后勤保障工作一应俱全，图书馆资料丰富，环境整洁。

感谢指导我、帮助我的老师们。李培培老师诲人不倦、治学严谨，从大学生创新项目初识到毕业设计指导透露着对学生的关怀，在辅导过程中认真负责，悉心指导。同样感谢李瑞轩老师、王俊博士、向俊夫博士在我的毕业设计中给出的指导。对所有为我们提供支持的合肥工业大学老师致以深深的敬意。

感谢同学们在过去四年的关怀与帮助，四年前我们萍水相逢，一同学习进步，一同参与社会活动，点点滴滴历历在目，今朝各奔前程，愿如大鹏一日同风起，扶摇直上九万里。

作者：任恒

2020年5月26日

附录

附录 1 类别筛选规则

预警	1、预警，不含制度 业绩 2、风险&警示，不含制度 业绩 3、风险&提示，不含制度 业绩	规则
重大事项	重大 重要，不含受托管理事务	规则
非标准意见	非标准意见	规则
变更偿还借款对象	变&偿还借款对象	规则
实控人变更	（实际控制人 实控人）&变，不含未 没 不	规则
变更法定代表人	变&法定代表人，不含未 没 不	规则+聚类
控股股东变更	1、股东&辞职 2、股东&聘任 3、变&股东，不含未 没 不	规则
董监高变更	1、（董 监 高管 高级管理人员 董高 董监高 总裁 经理）&辞职 2、（董 监 高管 高级管理人员 董高 董监高 总裁 经理）&聘任 3、变&（董 监 高管 高级管理人员 董高 董监高 总裁 经理），不含未 没 不 4、（调整 变）&组织架构	规则+聚类
工商变化	1、变&公司&名，不含未 没 不 2、变&工商登记，不含未 没 不 3、变&（地址 联系），不含未 没 不	规则+聚类
经营变化	变&（经营范围 方针 外部变化），不含未 没 不	规则+聚类
修改公司章程	（变 改）&公司章程，不含未 没 不	规则+聚类
变更发行场所	变&发行场所，不含未 没 不	规则
变更发行利差区间	变&发行利差，不含未 没 不	规则
变更发行期限	变&发行期限，不含未 没 不	规则
虚假标识	虚假&标识	规则
造假	造假 欺诈 骗 冒充 不真实 不准确	规则

财务报表差异	财务&差异	规则
变更会计估计	变&会计估计	
更正会计差错	更正&会计差错	规则
变更会计政策	变&会计政策, 不含未 没 不	规则+聚类
会计准则差异	会计准则&差异	规则
变更证券事务代表	证券事务代表&辞职 聘任	规则
信息披露负责人变化	信息披露负责人&变	
中介机构变化	变&（监管银行 事务所 审计机构 会计师 律师）	规则
变更募集资金投向、用途	变&募集资金&（项目 投向 用途），不含未 没 不	规则+聚类
偿债保障措施发生重大变化	保证人 担保物 偿债保障措施&重大变化	规则
变更承销团成员	变&承销团成员, 不含未 没 不	规则
变更债券资金监管人	变&债券资金监管人, 不含未 没 不	规则
债券信息变化	变&（债券代码 债券名称 债券简称），不含未 没 不	规则
标准券折算率下调	标准券折算率&（降 下调），不含未 没 不	规则
借款	借款，不含“超过”	规则+聚类
累计新增借款超过上年末百分之二十	累计新增借款&超过&上年末&（百分之二十 20%）	规则
累计新增借款超过上年末百分之四十	累计新增借款&超过&上年末&（百分之四十 40%）	规则
累计新增借款超过上年末百分之六十	累计新增借款&超过&上年末&（百分之六十 60%）	规则
累计新增借款超过上年末百分之八十	累计新增借款&超过&上年末&（百分之八十 80%）	规则
放弃资产超过上年末净资产百分之十	放弃&（债权 财产）&上年末净资产&（百分之十 10%）	规则
超过上年末净资产百分之十的重大损失	超过&上年末净资产&（百分之十 10%）&损失	规则

失		
未弥补亏损超过实收股本总额三分之一	未弥补亏损超过实收股本总额三分之一	规则+聚类
不良贷款增加	不良贷款&增	规则
贷后管理问题	贷后管理&问题	规则
非法放贷	非法放贷	规则
申请贷款	1、申请&贷款 2、申请&授信	规则+聚类
向关系人发放贷款	关系人&发放贷款	规则
经营问题	1、产品&不合格 2、反倾销 3、产品&（停产 停售） 4、产品&召回 5、经营&异 6、终止营业 终身禁业 7、项目&（停 止） 8、（停 止）&运营 9、运营能力&降 10、资金紧张 11、持续经营能力&风险	规则+聚类
设备故障、事故	设备&（故障 事故）	规则
资产运营报告	资产运营&报告	规则
生产恢复	生产&恢复	规则
业绩预警	业绩&预警	规则
业绩亏损	（销量 盈利 业绩 月销）&（降 减 少 下滑 亏 无）	规则
场外兑付	场外&兑付	规则
撤销回售申请	撤销&回售申请	规则
承诺履行	承诺履行	规则+聚类
尚未履行承诺	未&履行	规则
澄清	澄清	规则
创设认沽权证	创设&认沽权证	规则

注销认沽权证	注销&认沽权证	规则
认沽权证终止上市	认沽权证终止上市	规则
三会	董事会 监事会 股东大会	规则+聚类
债券持有人会议		聚类
发行计划	发行计划	规则
借款担保	（借款 贷款）&担保	规则
对外担保	1、对外&担保 2、提供担保	规则+聚类
对外投资	对外投资	规则
提供财务资助	提供财务资助	规则+聚类
分期偿还本金	分期&还本	规则+聚类
提前偿还本金	提前&还本	规则
风险提示	风险提示	规则+聚类
债券违约	1、无法按时 无法按期 未按时 未按期 未能按时 未能按期 不能按时 不能按期 2、违约，不含（无 股票 债务）	规则+聚类
质押股票违约	质押股票&违约	规则
违约率波动	违约率&波动	规则
投诉量增加	投诉&（增 加 多）	规则
重大诉讼、仲裁	诉讼 仲裁 纠纷 起诉 公诉 案件 判决 裁定 裁判 裁判 法院文件	规则+聚类
受到重大行政处罚	涉嫌犯罪 违法 违规 违纪 处罚 警告，不含（调查 立案 审查）	规则+聚类
公司/董监高被调查	1、（调查 立案 审查）&（董 监 高管 高级管理人员 董高 董监高 总裁 经理） 2、含（调查 立案 审查），不含（股东 实际控制人 实控人）	规则
公司/董监高被采取强制措施	1、强制措施&（董 监 高管 高级管理人员 董高 董监高 总裁 经理） 2、含“强制措施”，不含（股东 实际控制人 实控人）	规则
控股股东/实际控制人被调查	1、（调查 立案 审查）&（股东 实际控制人 实控人）	规则

	2、含（调查 立案 审查），不含（董 监 高管 高级管理人员 董高 董监高 总裁 经理）	
控股股东/实际控制人被采取强制措施	1、强制措施&（股东 实际控制人 实控人） 2、含“强制措施”，不含（董 监 高管 高级管理人员 董高 董监高 总裁 经理）	规则
公司/董监高列入失信被执行人	1、（董 监 高管 高级管理人员 董高 董监高 总裁 经理）&（列入 纳入）&失信被执行人 2、含（列入 纳入）&失信被执行人，不含（股东 实际控制人 实控人）	
控股股东/实际控制人列入失信被执行人	1、（股东 实际控制人 实控人）&（列入 纳入）&失信被执行人 2、含（列入 纳入）&失信被执行人，不含（董 监 高管 高级管理人员 董高 董监高 总裁 经理）	规则
公司/董监高移出失信被执行人	1、（董 监 高管 高级管理人员 董高 董监高 总裁 经理）&移出&失信被执行人 2、含“移出&失信被执行人”，不含（股东 实际控制人 实控人）	规则
控股股东/实际控制人移出失信被执行人	1、（股东 实际控制人 实控人）&移出&失信被执行人 2、移出&失信被执行人，不含（董 监 高管 高级管理人员 董高 董监高 总裁 经理）	规则
无违约违法	无&（违 诉讼 仲裁 处罚 纠纷 犯罪 调查）	规则+聚类
自律监管	自律监管	规则+聚类
业务不规范	业务&不规范	规则
催款	催款	规则
领罚单	领罚单	规则
被点名批评	批评	规则
关注函	关注函	规则
监管函	监管函	规则
警示函	警示函	规则
问询函	问询函	规则+聚类

延期回复交易所问询函	延期回复&问询函	规则
贪腐	贪腐 贪污 腐败 受贿 贿赂	规则
高层无法履职	高层&（无法 不）履职	规则
高隐含违约率	高&隐含违约率	规则
股票恢复上市	股票恢复上市	规则
暂停股票上市	暂停&股票&（上市 流通）	规则+聚类
股票终止上市	（终止 停止 取消）&股票&（上市 流通）	规则
暂停债券上市	暂停&（上市 流通），不含“股票”	规则
终止债券上市	（终止 停止 取消）&（上市 流通），不含“股票”	规则
债券取消发行	（债 票据 存单 凭证 资产支持 融资券）取消发行	规则+聚类
股票退市预警	股票&退市&（预警 警示）	规则
撤销股票退市预警	撤销&股票退市	规则
发生重大变化致不符合公司债券上市条件	重大变化&不符合&债&上市条件	规则
停牌	停牌，不含不 未	规则+聚类
复牌	复牌，不含不 未	规则
延期复牌	延期&复牌，不含不 未	规则
新三板挂牌		聚类
新三板终止挂牌		聚类
委托理财	委托理财	规则
购买理财产品		聚类
理财产品逾期	理财产品&逾期	规则
管理层失联	管理层&失联	规则
行权公告	行权	规则
豁免要约收购		聚类
资质、许可	资质 许可 获批 获得认证 获专利证书 获认可 获奖	规则+聚类
项目中标		聚类
获得政府补贴		聚类

技术性违约	技术性违约	规则
加强公司治理专项活动	加强&治理&专项活动	规则
竞拍得土地使用权		聚类
利润不确定	利润&不确定	规则
利润分配方案		聚类
两市价差明显	两市价差&明显	规则
变更募集资金投向、用途	变&募集资金&（项目 投向 用途），不含未 没 不	规则+聚类
募集资金的使用	募集资金&（用途 使用 项目）	规则+聚类
使用闲置募集资金进行现金管理	闲置募集资金&进行现金管理	规则
使用闲置募集资金暂补公司流动资金	闲置募集资金&暂补&流动资金	规则
内部控制问题	内部控制&问题	规则
内幕交易	内幕交易	规则
签订协议	（签订 签署）&（协议 合同）	规则+聚类
解除协议	解除&（协议 合同）	规则+聚类
认定核心员工	认定&核心员工	规则
融资进度	融资进度	规则
融资租赁		聚类
设立基金	设立&基金	规则
破产重整	含（破产 重整 清算），不含申请	规则+聚类
申请破产	申请破产	规则
解散	解散	规则
减资	减资	规则
增资	1、增资 2、增加&资本	规则+聚类
公款私用	公款私用	规则
停工整改	停工 整改	规则
退出提供市报价服务	退出&提供市报价服务	规则+聚类
加入提供市报价服	加入&提供市报价服务	规则+聚类

务		
未按时披露财报	1、未按时披露财报 2、推迟 延迟 延期&披露财报	规则+聚类
推迟出具跟踪评级报告		聚类
债权代理协议	债权代理%协议	规则
债券价格异常	债&价&异常	规则
债券回售	回售	规则+聚类
债券赎回	赎回	规则
债券递延付息	递延&付息	规则
债务暴雷	债务暴雷	规则
债务到期未能清偿	1、债务&（逾期 未清偿 违约） 2、债务&欠息	规则
股权激励异常	股权激励异常	规则
招投标、合同进展	（招投标 合同）&进展	规则
终止公开独立意见	（止 停 取消）&公开独立意见	规则
终止公告	（止 停 取消）&公告	规则
重大事故、人员伤亡	事故 伤 亡	规则
重大追溯调整	重大&追溯调整	规则
资金挪用、占用	资金&（挪用 占用）	规则+聚类
自然灾害、不可抗力	灾 不可抗力	规则
收购	收购，不含豁免	规则+聚类
回购股份	回购股份	规则+聚类
质押式回购	质押式回购	规则+聚类
质押式回购违约	质押式回购&（延期 逾期 违约）	规则
解除质押式回购	解除&质押式回购	规则
解除股权质押	1、解除&（股权 股份 股票）&质押，不含质押式回购 2、解押&（股权 股份 股票），不含质押式回购	规则+聚类
股票暂停转让		聚类
股票恢复转让		聚类
股票延期恢复转让		聚类

资产、股权质押	（资产 股权 股份 股票）&质押，不含解除 不含质押式回购	规则+聚类
资产、股权转让	（资产 股权 股份 股票）&转让	规则+聚类
资产、股权无偿划转	（资产 股权 股份 股票）&无偿划转	规则+聚类
资产、股权出售	（资产 股权 股份 股票）&出售	规则
资产、股权冻结	（资产 银行账户 股权 股份 股票）&（查封 扣押 冻结）	规则+聚类
资产、股权解除冻结	（资产 银行账户 股权 股份 股票）&解除冻结	规则
司法拍卖	司法拍卖	规则
计提资产减值准备	计提&资产减值	规则+聚类
资产受限	受限&资产	规则
股权变动	股权&变	规则
股改进展		聚类
股价暴跌	股价&暴跌	规则
股票交易异常波动	1、股票&交易&异常 2、股价异动 股价异常波动 股票价格异动 股票价格异常波动	规则+聚类
股票解禁	1、解禁 2、限制性股票解锁上市	规则
市场化债转股	市场化债转股	规则
调整可转债转股价	（调 修正）&可转债&转股价	规则
可转债转股	可转债&转股	规则
股权激励计划	股权激励计划	规则
股权激励异常	股权激励&异	规则
调整股权激励对象名单	（调 变）&股权激励对象名单	规则
维护公司股价稳定		聚类
员工持股计划		聚类
增持股份		聚类
减持股份	减持&股份	规则+聚类
增资扩股	增资扩股	规则+聚类
注销股份	注销&（股份 股票）	规则

注销公司	注销&公司	规则
注销募集资金专户	注销&募集资金专户	规则
注销许可证	注销&许可证	规则
重大资产优化	资产&优化	规则
资产重组	1、（资产 并购）&重组，不含停牌 复牌 风险揭示 2、股份购买资产，不含停牌 复牌 风险揭示	规则+聚类
资产重组风险揭示		聚类
受托机构报告	受托机构报告	规则
定向增发	定向增发 定增	规则
信用增进	信用增进函	规则
维持评级	维持&评级	规则
列入评级观察	列入&评级观察	聚类
债券评级变化	（债 票据 存单 凭证 资产支持 融资券）&评级&变	规则
债券评级上调	（债 票据 存单 凭证 资产支持 融资券）&评级&（上调 调升）	规则
债券评级下调	（债 票据 存单 凭证 资产支持 融资券）&评级&（下调 调降）	规则+聚类
终止评级	（终止 停止）&评级	规则
主体评级变化	（主体 公司）评级&变	规则
主体评级上调	（主体 公司）评级&（上调 调升）	规则
主体评级下调	（主体 公司）评级&（下调 调降）	规则
调整评级展望	（调 变）&评级展望	规则
主权评级展望下调为负	（主体 公司）评级&负	规则
关联方为公司提供担保		聚类
关联方为公司提供反担保	关联方&为公司提供反担保	规则
关联交易		聚类
预计日常性公司关		聚类

联交易		
设立分公司、子公司	设立&分公司 子公司	规则+聚类
子公司完成工商登记		聚类
注销子公司		聚类
合并子公司		聚类
收到子公司分红款		聚类
失去对子公司的控制	失去&子公司&控	规则
关联方	含子公司 孙公司 分公司 关联方	规则